

# Taller de estimación de variables latentes

Eric Magar  
Guillermo Rosas  
y el amable apoyo de Ernesto Barrios

ITAM – Junio 2011

## Introducción

- Variables latentes

- Inferencia bayesiana

- R, RStudio y Jags (Barrios)

## Regresión lineal: El efecto de arrastre de ejecutivos

- Estimación clásica

- Estimación bayesiana

## IRT I: Introducción, teoría espacial del voto, CDHCU

## IRT II: Modelos jerárquicos, dinámicos, multidimensionales

## Modelos con variables latentes: análisis factorial bayesiano

## Introducción

- Variables latentes

- Inferencia bayesiana

- R, RStudio y Jags (Barrios)

Regresión lineal: El efecto de arrastre de ejecutivos

- Estimación clásica

- Estimación bayesiana

IRT I: Introducción, teoría espacial del voto, CDHCU

IRT II: Modelos jerárquicos, dinámicos, multidimensionales

Modelos con variables latentes: análisis factorial bayesiano

# Variables latentes y su potencial gráfico

1. A menudo interesa medición de variables que no pueden ser observadas directamente
2. Deben ser inferidas de indicadores que sí son observables
3. Un *modelo de variable latente* conecta (2) a (1)

## Ejemplos

- ▶ **Sicometría:** habilidad, personalidad autoritaria
- ▶ **Mercadotecnia:** demanda de productos, *herd behavior*
- ▶ **Economía:** confianza del consumidor, felicidad
- ▶ **CPol:** ideología, preferencias en regulación

## Poole (2005)


Un procedimiento capaz de capturar la estructura subyacente de tus datos (votos) permite

1. tomar una serie de números
2. transformarlos en gráficas simples
3. que comunican significado

Resumes información compleja con dibujos


*Un bon croquis vaut mieux qu'un long discours*  
—(atribuido a) Napoleón Bonaparte

*Un bon croquis vaut mieux qu'un long discours*  
—(atribuido a) Napoleón Bonaparte




# Aproximación gráfica

## IASBS EQUINATIONAL PROJECTION





**FIGURE 3** Simulated Electoral Outcomes



Coordinates in this ternary diagram are predicted fractions of the vote received by each of the three candidates. Each point is an election outcome drawn randomly from a world in which all voters believe Salinas' PRI party is strengthening (for the "o"s in the bottom left) or weakening (for the "."s in the middle), with other variables held constant at their means.

Poole recurre a la “basic-space theory of ideology” para resumir/interpretar votaciones nominales con dibujos

1. Teoría espacial del voto (cf. Downs)
2. Sistema de creencias restringe la dimensionalidad (cf. Converse)

## Escalamiento multidimensional

1. Métodos agnósticos: factorial, componentes principales, clasificación óptima, ...
2. Microfundamentos dan la estructura: item response theory, utilidad euclidiana, ...

# Ventajas de la estadística bayesiana

1. La inferencia bayesiana es **simple** y **directa**: Depende de enunciados *a posteriori* que reflejan nuestras creencias acerca de parámetros, hipótesis, modelos o datos faltantes
2. La inferencia bayesiana permite responder **preguntas relevantes**: ¿qué tan plausible es la hipótesis  $H_0$  en vista de los datos que tenemos?
3. La inferencia bayesiana permite el análisis de **eventos no repetibles**
4. La inferencia bayesiana facilita el análisis de relaciones causa-efecto en situaciones de **heterogeneidad causal** (modelos jerárquicos)

# ¿Qué es probabilidad?

## Axiomas de Kolmogorov

Si  $\Omega$  es un conjunto de eventos y  $\Pr(A)$  es una función que asigna un número real a cada evento  $A \subset \Omega$ ,  $\Pr(A)$  es una medida de probabilidad si:

1.  $\Pr(A) \geq 0, \quad \forall A \subset \Omega$
2.  $\Pr(\Omega) = 1$
3. Si  $A \subset \Omega$  y  $B \subset \Omega$  son conjuntos inconexos,  
 $\Pr(A \cup B) = \Pr(A) + \Pr(B)$

# ¿Qué es probabilidad?

## Visiones alternativas

- ▶ **Visión “frecuentista” (clásica):** La probabilidad es la frecuencia relativa de un evento en el largo plazo, y es una propiedad del objeto que se estudia
- ▶ **Visión “subjetivista” (bayesiana):** La probabilidad es una expresión del grado de certeza que uno tiene acerca de la veracidad de cierta hipótesis

# Teorema de Bayes (regla de probabilidad inversa)

Si  $H$  es una hipótesis, y  $E$  representa evidencia, la respuesta a la pregunta sobre la plausibilidad de la hipótesis  $H$  dada la evidencia  $E$  es:


$$\underbrace{\Pr(H|E)}_{\text{a posteriori}} = \frac{\Pr(E \cap H)}{\Pr(E)} = \frac{\overbrace{\Pr(E|H)}^{\text{verosimilitud}} \overbrace{\Pr(H)}^{\text{a priori}}}{\Pr(E)}$$

De manera más general,

$$\Pr(\psi|\mathbf{y}) \propto \Pr(\mathbf{y}|\psi) \Pr(\psi),$$

es decir, la distribución *a posteriori* es proporcional al producto de la distribución *a priori* y la función de verosimilitud

densidad a priori  $\times$  verosimilitud = densidad a posteriori



a priori  $\rightarrow$  datos  $\rightarrow$  a posteriori

$$p(\psi) \rightarrow y \rightarrow p(\psi|y)$$

**Inferencia bayesiana:** El enunciado condicional tiene que ver con la probabilidad de que el parámetro esté en cierto rango, dado que observamos ciertos datos

**Inferencia frecuentista:** El enunciado condicional tiene que ver con la probabilidad de observar ciertos datos, dado que suponemos la veracidad de la hipótesis nula



# Chabelo es bayesiano, los cuates de Chabelo no



- Información disponible:

$$\Pr(A) = \Pr(B) = \Pr(C) = 1/3$$

$$\Pr(\text{Ch abra } C|A) = 1/2$$

$$\Pr(\text{Ch abra } C|B) = 1$$

$$\Pr(\text{Ch abra } C|C) = 0$$

- El niño abre la puerta A:

$$\Pr(A) = \Pr(B) = \Pr(C) = \frac{1}{3}$$

- Chabelo abre la puerta C:

$$\Pr(A) = \Pr(B) = \frac{1}{2}$$

- El niño se queda con la puerta A

- Probabilidad de que Chabelo abra C:

$$\begin{aligned}\Pr(\text{Ch abra } C) &= \Pr(A) \Pr(\text{Ch abra } C|A) \\ &\quad + \Pr(B) \Pr(\text{Ch abra } C|B) \\ &\quad + \Pr(C) \Pr(\text{Ch abra } C|C)\end{aligned}$$

- Teorema de Bayes:

$$\Pr(A|\text{Ch abra } C) = \frac{\Pr(A) \Pr(\text{Ch abra } C|A)}{\Pr(\text{Ch abra } C)}$$

$$\Pr(B|\text{Ch abra } C) = \frac{\Pr(B) \Pr(\text{Ch abra } C|B)}{\Pr(\text{Ch abra } C)}$$

# ¿Qué es R?

- ▶ Es una colección de herramientas para manipular datos, llevar a cabo cálculos y preparar gráficas
- ▶ Numerosas técnicas estadísticas han sido desarrolladas:
  - ▶ algunas pre-empaquetadas en la instalación de R
  - ▶ otras (las más) como paquetes extensibles  
<http://www.youtube.com/watch?v=Z0-93iULKBI>
- ▶ Código de fuente abierta: Encyclopaedia Britannica v. Wikipedia
- ▶ Muchísima ayuda en línea  
<http://www.burns-stat.com/>

# Algunas complicaciones

- ▶ Consola abre con pantalla blanca y '>'  
*turn-off* para tantas generaciones que han crecido con mouse
- ▶ R crea objetos que no necesariamente tienen que ser rectangulares. Salir de la camisa de fuerza desconcierta
- ▶ Todo es *case sensitive* (funciones y nombres de objeto)
- ▶ En vez de sacar output copioso como SPSS, el análisis en R va guardando los resultados como objetos. El usuario los interroga para sacar conclusiones
- ▶ R suele operarse a partir de código (tipo *do file* de Stata) que se prepara en un editor de texto — usaremos RStudio para esto

COMANDOS EN R

## Introducción

Variables latentes

Inferencia bayesiana

R, RStudio y Jags (Barrios)

## Regresión lineal: El efecto de arrastre de ejecutivos

Estimación clásica

Estimación bayesiana

IRT I: Introducción, teoría espacial del voto, CDHCU

IRT II: Modelos jerárquicos, dinámicos, multidimensionales

Modelos con variables latentes: análisis factorial bayesiano


- ▶ El desenlace de una elección resulta de la combinación de dos clases de fuerzas (Converse 1966)
  1. largo plazo: encapsuladas en PID, cambio lento, “voto normal”
  2. corto plazo: calidad de candidatos, swings nacionales, shock efímero al voto normal
- ▶ Arrastre presidencial es una de las fuerzas de corto plazo
- ▶ EE.UU.: 1980s =  $\frac{1}{3}$ ; 1940s =  $\frac{1}{2}$ ; 1890s =  $\frac{9}{10}$  (Campbell 1991)
- ▶ ¿Elección concurrente de gobernador también produce un efecto de arrastre? (Jones 1997, Samuels 2000)

$$\begin{aligned} Dvot = & \beta_0 + \beta_1 RecentDvot + \beta_2 GovOnlyConcurs \\ & + \beta_3 PresOnlyConcurs + \beta_4 Gov\&PresConcur \\ & + \beta_5 Gvote|GovOnlyConcurs + \beta_6 Gvote|Gov\&PresConcur \\ & + \beta_7 Pvote|PresOnlyConcurs + \beta_8 Pvote|Gov\&PresConcur \\ & + \text{controles} + \text{error} \end{aligned}$$


- ▶ Elecciones de diputados federales 1997–2009
- ▶ Unidad de análisis: estados
- ▶ Panel  $32 \times 5$

# Elecciones de diputados federales por estado


PAN



PRI



PRD








# Resultados OLS

Variable	OLS		OLS-PCSE	
	$\hat{\beta}$	$p$	$\hat{\beta}$	$p$
<b>Part A. PAN</b>				
Constant	.135	.000	.135	.000
<i>RecentDvote</i>	.586	.000	.586	.000
<i>GovOnlyConcurs</i>	-.151	.000	-.151	.005
<i>PresOnlyConcurs</i>	-.097	.000	-.097	.054
<i>Gov&amp;PresConcur</i>	-.106	.000	-.106	.102
<b><i>Gvote GovOnlyConcurs</i></b>	.584	.000	.584	.000
<i>Gvote Gov&amp;PresConcur</i>	.444	.000	.444	.043
<b><i>Pvote PresOnlyConcurs</i></b>	.446	.000	.446	.002
<i>Pvote Gov&amp;PresConcur</i>	.018	.848	.018	.956
<i>IncumbentGovernor</i>	.045	.030	.045	.021
<i>IncumbentPresident</i>	-.047	.002	-.047	.004
<i>Economy</i>	-.145	.451	-.145	.465
<i>PartyCoalesced</i>	.016	.319	.016	.416
N	160		160	
$R^2$	.82		.82	

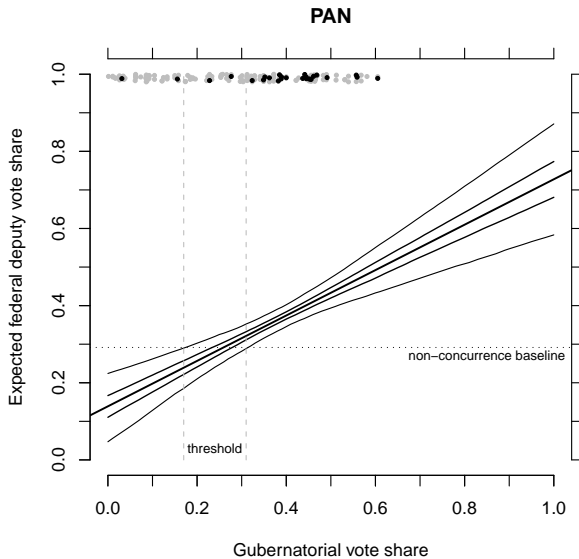
# Regresión en R: función `lm`

# Regresión bayesiana en R: función MCMCregress

# Resultados MCMC



# El efecto de arrastre neto de gobernadores



# ¿Resultados idénticos?

Coeficiente de RecentDvote

## 1. Versión frecuentista:

$$\hat{\beta}_{ML} \approx 0.59, \quad \text{se}(\hat{\beta}) \approx 0.06, \quad H_0 = 0.45$$

$$z = \frac{\hat{\beta}_{ML} - H_0}{\text{se}(\hat{\beta})} \approx 2.33$$

La frecuencia con que uno observaría  $\hat{\beta}_{ML} \geq 0.59$  bajo  $H_0$  en el largo plazo es 0.009.

## 2. Versión bayesiana:


$$p(\beta) \sim \mathcal{N}(0, 100^2); \quad p(\beta|Y, X) \sim \mathcal{N}(0.59, 0.06^2)$$

$$\begin{aligned} \Pr(\beta \leq 0.45|Y, X) &= \int_{-\infty}^{0.45} p(\beta|Y, X) d\beta \\ &= \int_{-\infty}^{0.45} \phi\left(\frac{0.59 - .45}{0.06}\right) d\beta = .009 \end{aligned}$$


# ¿Resultados idénticos?

Coeficiente de RecentDvote

Distribución de muestreo



Densidad a posteriori







# ¿Resultados idénticos?

Coeficiente de RecentDvote

Distribución de muestreo



Densidad a posteriori



# ¿Resultados idénticos?

Coeficiente de RecentDvote

$$H_1 : \beta > .45$$

$$H_0 : \beta \leq .45$$

El factor bayesiano que resume la cantidad de evidencia a favor de  $H_1$  es:

$$\begin{aligned} B_{10} &= \left\{ \frac{p(H_1|y)}{p(H_0|y)} \right\} / \left\{ \frac{p(H_1)}{p(H_0)} \right\} \\ &= \left\{ \frac{1 - .009}{.009} \right\} / \left\{ \frac{.5}{.5} \right\} \\ &= 110.11 \end{aligned}$$

¿Cómo podemos estimar la probabilidad de que el coeficiente de RecentDVote sea negativo?

¿Cómo podemos estimar la probabilidad de que el coeficiente de RecentDVote se encuentre entre 0.3 y 0.45?

# La tentación de la probabilidad inversa en el frecuentismo

## 1. Modus tollens

$$P \rightarrow Q; \neg Q; \vdash \neg P$$

## 2. Modus tollens probabilístico?

- ▶ Si un individuo es mexicano, es *improbable* que sea miembro de la Cámara de Diputados
- ▶ Este individuo es miembro de la Cámara
- ▶ Es *improbable* que este individuo sea mexicano

## 3. Inverse probability problem

$$\underbrace{\Pr(H_0|D)}_{\text{mexicano|diputado}} \propto \Pr(H_0) \times \underbrace{\Pr(D|H_0)}_{\text{diputado|mexicano}}$$

- ▶ Modelo de regresión lineal:

$$y_i \sim \mathcal{N}(\mu_i, \sigma^2)$$

$$\mu_i = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k = \mathbf{x}_i \boldsymbol{\beta}$$

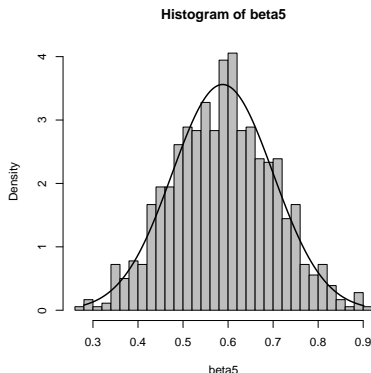
- ▶ La inferencia deseada es sobre  $\boldsymbol{\beta} = [\beta_0 \dots \beta_k]$  y  $\sigma^2$
- ▶ Densidades a priori:

$$\boldsymbol{\beta} | \sigma^2, \mathbf{y}, \mathbf{X} \sim \mathcal{N}(\mathbf{b}_0, \sigma^2 \mathbf{B}_0)$$

$$\sigma^2 \sim \text{Gamma-inversa} \left( \frac{\nu_0}{2}, \frac{\nu_0 \sigma_0^2}{2} \right)$$

# Densidades conjugadas

- ▶ Cuando las densidades a priori y a posteriori son de la misma familia, se dice que la densidad a priori y la verosimilitud están *conjugadas*
- ▶ Si uno es capaz de proveer un a priori no tendrá dificultad en interpretar el a posteriori conjugado
- ▶  $\beta_5 \sim \mathcal{N}(0, 100^2)$  — a priori no informativo



# Densidades conjugadas

Sea  $y_i \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2)$  (donde  $i = 1, \dots, n$ ), con  $\sigma^2$  conocida y  $\mathbf{y} = (y_1, \dots, y_n)'$ . Si  $\mu \sim \mathcal{N}(\mu_0, \sigma_0^2)$  es la distribución a priori de  $\mu$ , la distribución a posteriori es:

$$\mu|\mathbf{y} \sim \mathcal{N}\left(\frac{\mu_0\sigma_0^{-2} + \bar{y}\frac{n}{\sigma^2}}{\sigma_0^{-2} + \frac{n}{\sigma^2}}, \left(\sigma_0^{-2} + \frac{n}{\sigma^2}\right)^{-1}\right)$$

Si la distribución a priori y la verosimilitud son conjugadas, la densidad a posteriori es una mezcla ponderada de ambas densidades, donde el ponderador es la precisión respectiva de ambas densidades:

$$E(\mu|\mathbf{y}) = \bar{y} + \omega(\mu_0 - \bar{y})$$

$$\omega = \frac{\sigma_0^{-2}}{\sigma_0^{-2} + \frac{n}{\sigma^2}}$$

# Regresión lineal: densidades

(continuación)

- Distribución a posteriori

$$\beta | \sigma^2, \mathbf{y}, \mathbf{X} \sim \mathcal{N}(\mathbf{b}_1, \sigma^2 \mathbf{B}_1)$$

$$\sigma^2 \sim \text{inverse Gamma} \left( \frac{\nu_1}{2}, \frac{\nu_1 \sigma_1^2}{2} \right)$$

- Los parámetros a posteriori son un “compromiso” entre la información a priori y la información proporcionada por los datos:

$$\mathbf{b}_1 = (\mathbf{B}_0^{-1} + \mathbf{X}'\mathbf{X})^{-1}(\mathbf{B}_0^{-1}\mathbf{b}_0 + \mathbf{X}'\mathbf{X}\hat{\theta})$$

$$\mathbf{B}_1 = (\mathbf{B}_0^{-1} + \mathbf{X}'\mathbf{X})^{-1}$$

# MCMC: principio de Monte Carlo y cadenas de Markov

- ▶ **Principio de Monte Carlo:** Todo lo que querramos saber acerca de una variable  $\psi$  lo podemos averiguar tomando muchas muestras de la densidad  $f(\psi)$  de  $\psi$
- ▶ **Cadenas de Markov:** Una cadena de Markov es un proceso estocástico definido sobre cierto espacio paramétrico. Tiene la propiedad de ser un proceso *ergódico*: una cadena de Markov visita cada región del espacio paramétrico en proporción a la probabilidad de esa región dada una densidad de interés



# A priori, verosimilitud, a posteriori

Se puede aproximar una densidad a posteriori sin recurrir al análisis matemático

```
library(LearnBayes)

midpt = seq(0.05, 0.95, by = 0.1)
prior = c(1, 5.2, 8, 7.2, 4.6, 2.1, 0.7, 0.1, 0, 0)
prior = prior/sum(prior)

curve(histprior(x,midpt,prior), from=0, to=1,
      ylab="Prior density",ylim=c(0,round (max(prior),2)))

s = 11
f = 16

curve(dbeta(x,s,f), from=0, to=1, ylab="Data likelihood")







curve(histprior(x,midpt,prior) * dbeta(x,s,f),
      from=0, to=1, ylab="Posterior density")
```

# Algoritmo de Gibbs







El algoritmo de muestreo de Gibbs (Gibbs sampler) obtiene muestras de las *densidades condicionales* de los parámetros para caracterizar la *densidad conjunta* de los parámetros:

```
gibbs<-function (n, rho)  {  
  # Open plotting window  
  plot (c(-3.5,3.5),c(-3.5,3.5), type="n", xlab="x", ylab="y")  
  mat <- matrix(ncol = 2, nrow = n)  
  # Assign starting values  
  x <- 0  
  y <- 0  
  mat[1, ] <- c(x, y)  
  points (xy.coords(x,y), pch="1", col="black")  
  for (i in 2:n) {  
    # Sample x2 from p(x|y1)  
    x <- rnorm(1, rho * y, sqrt(1 - rho^2))  
    # Sample y2 from p(y|x2)  
    y <- rnorm(1, rho * x, sqrt(1 - rho^2))  
    mat[i, ] <- c(x, y)  
    points (xy.coords(x,y), pch=as.character(i),  
            col="grey")  
  }  
  mat
```

# Algoritmo de Gibbs: Después de 15 muestras



# Algoritmo de Gibbs: Después de 1,000 muestras



# Algoritmo de Gibbs: Comparación con resultados analíticos

Jackman 2009, tabla 5.3

	Analítico	1000 muestras	50000 muestras
$E(\mu_1 \mathbf{y})$	29.44	30.34	29.38
$E(\mu_2 \mathbf{y})$	37.72	38.63	37.65
$V(\mu_1 \mathbf{y})$	38.41	35.54	38.91
$V(\mu_2 \mathbf{y})$	43.17	40.12	43.84
$C(\mu_1, \mu_2 \mathbf{y})$	30.59	28.07	31.12

## Introducción

Variables latentes

Inferencia bayesiana

R, RStudio y Jags (Barrios)

## Regresión lineal: El efecto de arrastre de ejecutivos

Estimación clásica

Estimación bayesiana

## IRT I: Introducción, teoría espacial del voto, CDHCU

## IRT II: Modelos jerárquicos, dinámicos, multidimensionales

## Modelos con variables latentes: análisis factorial bayesiano

# Item Response Theory

- ▶ Modelo estándar de éxito/fracaso en pruebas es el **logístico de respuesta a ítems** (sicometría, Rasch)
- ▶  $J$  sujetos contestan prueba de aptitudes con  $K$  preguntas puede expresarse como (Gelman&Hill 2007:314)

$$\Pr(y_{jk} = 1) = \text{logit}^{-1}(\alpha_j - \psi_k)$$

donde  $\alpha_j$  es la habilidad del sujeto  $j$   
y  $\psi_k$  la dificultad de la pregunta  $k$

- ▶ Si preg. 4 tiene dificultad 1.4 y sujeto 13 habilidad 3.8, la prob. de que conteste correctamente el ítem 4 es  $\text{logit}^{-1}(2.4) = .92$
- ▶ Trivial generalizarlo para estudiar el voto

- ▶ Mapas políticos de una legislatura son fáciles de hacer
- ▶ Cuatro ingredientes:
  1. Datos
  2. Técnica de escalamiento
  3. Modelo de variable latente
  4. Conocimiento sustantivo — política de la legislatura
- ▶ Sin #3 o sin #4, el mapa carece de significado

Elaboramos el **modelo de variable latente**  
(ojo: reto real es #4)




El modelo de variable latente que usaremos conjuga avances en psicología, economía, ciencia política, ... (Poole 2005)

Desarrollo de la versión determinista

1. Hotelling (1929) competencia en pueblo lineal
2. Smithies (1941) demanda elástica
3. Black (1948, 1958) generaliza a comités
4. Downs (1957) generaliza a candidatos, populariza
5. Davis, Hinich, Ordeshook (1966, 1970) completan formalización para aplicaciones empíricas

1. Preferencias y alternativas pueden representarse en un mismo **espacio** ( $\mathbb{R}, \mathbb{R}^2, \mathbb{R}^n$ )
2. Preferencias **euclidianas**: se opta por la alternativa más cercana al punto ideal ( $\pm$  error)
  - ▶  $u(x) = ||i, x||$ ,  $i$  es el ideal,  $x$  una alternativa
  - ▶ opción 1:  $u(x) = -|i - x|$
  - ▶ opción 2:  $u(x) = -(i - x)^2$
  - ▶ opción 3:  $u(x) = \phi(i - x, \sigma^2)$
3. El voto es **sincero**  
(sin *logrolls* ni voto estratégico)

# Especificación unidimensional



Cálculo del voto:

- ▶  $u(p) > u(q)$  votas sí
- ▶  $u(p) \leq u(q)$  votas no


El diferencial de utilidad:  $d = u(p) - u(q) \stackrel{?}{\leq} 0$

$p$  = propuesta,  $q$  = status quo,  $i$  = ideal del votante


$$\begin{aligned}d &= u(p) - u(q) \\&= -(i - p)^2 + (i - q)^2 \\&= -(i^2 - 2ip + p^2) + i^2 - 2iq + q^2 \\&= -2iq + q^2 + 2ip - p^2 \\&= -2i(q - p) + q^2 - p^2 \\&= -2i(q - p) + (q + p)(q - p) \\&= -2(q - p) \left( i - \frac{(q + p)}{2} \right) \\&= \delta(i - m)\end{aligned}$$

# La centralidad del punto medio

Basta conocer  $m$  para deducir la conducta asociada con  $i$



$$i - m < 0 \Leftrightarrow i < m \rightarrow \text{votas no}$$



$$i - m > 0 \Leftrightarrow i > m \rightarrow \text{votas sí}$$

Propensión al voto del sujeto  $j$  para el ítem  $k$ :

$$v_{jk}^* = \delta_k(i_j - m_k) + \text{error}_{jk}$$

- ▶ Regla de votación:  $v_{jk} = \begin{cases} 1 & \text{si } v_{jk}^* > 0 \\ 0 & \text{si } v_{jk}^* \leq 0 \end{cases}$
- ▶ Signo de  $\delta_k$  controla la polaridad
- ▶ Tamaño de  $|\delta_k|$  estima el peso relativo del componente sistemático vs. el estocástico (*signal-to-noise ratio*)

## Operacionalización

Si  $\text{error}_{jk} \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2) \rightarrow v_{jk}^* \sim \mathcal{N}(\mu_{jk}, \sigma^2)$  donde  $\mu_{jk} = \delta_k(i_j - m_k)$

$$\begin{aligned}d &= ||i, p|| - ||i, q|| \\&= \sqrt{(x_i - x_p)^2 + (y_i - y_p)^2} - \sqrt{(x_i - x_q)^2 + (y_i - y_q)^2}\end{aligned}$$

Dado que cuando  $a, b \geq 0 : a > b \leftrightarrow a^2 > b^2$ , raíces se van

$$\begin{aligned}d &= (x_i - x_p)^2 + (y_i - y_p)^2 - [(x_i - x_q)^2 + (y_i - y_q)^2] \\&= (x_i - x_p)^2 - (x_i - x_q)^2 + (y_i - y_p)^2 - (y_i - y_q)^2 \\&= [(x_i - x_p) + (x_i - x_q)] [(x_i - x_p) - (x_i - x_q)] \\&\quad + [(y_i - y_p) + (y_i - y_q)] [(y_i - y_p) - (y_i - y_q)] \\&= (2x_i - x_q - x_p)(x_q - x_p) + (2y_i - y_q - y_p)(y_q - y_p) \\&= 2x_i x_q - 2x_i x_p - x_q^2 + x_p^2 + 2y_i y_q - 2y_i y_p - y_q^2 + y_p^2\end{aligned}$$

## 1. Aditiva (Gelman&Hill 2007:319)

$$\begin{aligned}d &= 2x_i x_q - 2x_i x_p - x_q^2 + x_p^2 + 2y_i y_q - 2y_i y_p - y_q^2 + y_p^2 \\&= -2(x_q - x_p) \left( x_i - \frac{(x_q + x_p)}{2} \right) - 2(y_q - y_p) \left( y_i - \frac{(y_q + y_p)}{2} \right) \\&= \delta_x (x_i - m_x) + \delta_y (y_i - m_y)\end{aligned}$$

- ▶ Ésta es la que usaremos en la **estimación**
- ▶ Permite controlar polaridad de cada dimensión fácilmente





## 2. Bisectriz (*cutlines*)

Igualamos  $d = 0$  para despejar  $y_v$

$$\begin{aligned}-2y_i y_q + 2y_i y_p &= 2x_i(x_q - x_p) - \left((x_q^2 - x_p^2) + (y_q^2 - y_p^2)\right) \\ y_i &= -\frac{x_q - x_p}{y_q - y_p} x_i + \frac{(x_q^2 - x_p^2) + (y_q^2 - y_p^2)}{2(y_q - y_p)} \\ &= \delta a x_i + \delta b \\ &= \delta(a x_i + b)\end{aligned}$$

- Ésta la usaremos en la **ilustración**





$y_i < ax_i + b \rightarrow$  vota **no**

La teoría espacial del voto puede aplicarse

1. fijando preferencias para explicar conducta  
(Downs 1957, Romer&Rosenthal 1978)
2. fijando conducta para inferir preferencias  
(Poole&Rosenthal 1985, Martin&Quinn 2002)

## **Haremos lo segundo:**

inferir las preferencias políticas  
de los diputados a partir de  
sus votaciones nominales

# “Data augmentation” en el modelo IRT

1. La clave es pensar en una variable latente que subyace cada respuesta dicotómica, de la siguiente manera:

$$y_{ij} = \begin{cases} 1 & \text{si } y_{ij}^* \geq 0 \\ 0 & \text{si } y_{ij}^* < 0 \end{cases}$$

2. La variable latente  $y_{ij}^*$  se puede interpretar como la propensión a votar *a favor* de una propuesta, y es una función de parámetros correspondientes a *individuos* y *propuestas*

$$y_{ij}^* = \beta_j(\theta_i - \alpha_j)$$

3. Alternativamente, podemos escribir


$$\Pr(y_{ij} = 1) = \Phi(y_{ij}^*),$$

es decir, una función “probit”

Interesa obtener una muestra de la densidad posterior conjunta de parámetros y variables latentes. El algoritmo repite tres pasos en cada turno:

1.  $g(\mathbf{y}^*|\boldsymbol{\theta}, \boldsymbol{\alpha}, \boldsymbol{\beta}, \mathbf{y})$  es una densidad normal truncada con media  $\beta_j^{t-1}\theta_i^{t-1} - \alpha_j^{t-1}$  (data augmentation)
2.  $g(\boldsymbol{\theta}|\mathbf{y}^*, \boldsymbol{\alpha}, \boldsymbol{\beta}, \mathbf{y})$  es una densidad normal con media  $m_{x_i}$  y varianza  $\nu_{x_i}$
3.  $g(\boldsymbol{\alpha}, \boldsymbol{\beta}|\boldsymbol{\theta}, \mathbf{y}^*, \mathbf{y})$  es también una densidad normal con media  $m_j$  y varianza  $\nu_j$

# ¿Para qué sirven los parámetros de discriminación y dificultad?



# Múltiples rotaciones y escalamientos de los parámetros

El modelo básico  $y_{ij}^* = \beta_j(\theta_i - \alpha_j)$  no está identificado:

- ▶ **Escalas múltiples:** El modelo no cambia si usamos  $\theta'_i = k + \theta_i$  y  $\alpha'_j = k + \alpha_j$
- ▶ **Rotaciones múltiples:** El modelo no cambia si usamos  $\theta'_i = k \cdot \theta_i$  y  $\beta'_j = \beta_j/k$  y  $\alpha'_j = \alpha_j/k$



En resumen, hay un número infinito de soluciones para  $\theta$ ,  $\alpha$  y  $\beta$



# Densidades a priori para los parámetros del modelo IRT

Comúnmente se usan las densidades a priori de los parámetros  $\theta$ ,  $\alpha$  y  $\beta$  para identificar el modelo IRT:

1. La escala del modelo se puede fijar con una densidad a priori sobre los puntos ideales:

$$\Pr(\theta) \sim \mathcal{N}(0, 1)$$

2. De manera similar, una densidad a priori de tipo

$$\Pr(\alpha) = \Pr(\beta) \sim \mathcal{N}(0, 2)$$

permite estimar los parámetros de discriminación y dificultad en una escala similar

3. La polaridad del modelo se puede fijar “anclando” un par de puntos ideales ( $\theta$ ) o un par de parámetros de discriminación ( $\beta$ )

# Modelo unidimensional del Congreso mexicano

MCMCpack (Martin, Quinn, Park)

```
posterior.1D <- MCMCirtKd(Roll.Call,  
  dimensions=1,  
  store.item=TRUE, store.ability=TRUE,  
  burnin=15000, mcmc=30000, thin=10,  
  seed=1971,  
  item.constraints=list(  
    vote.left=list(2,"-"),  
    vote.right=list(2,"+")),  
  b0=0, B0=.25)
```

# ¿Qué es BUGS/JAGS?

- ▶ Es una serie de módulos que permiten estimar modelos bayesianos mediante simulaciones MCMC
  - ▶ WinBUGS sólo funciona en plataforma Windows
  - ▶ JAGS se puede compilar en todo tipo de plataformas
- ▶ Código de fuente abierta
- ▶ Mucha ayuda para WinBUGS; relativamente poca para JAGS
- ▶ Los mensajes de error son muy poco informativos

# Modelo unidimensional del Congreso mexicano

JAGS (Plummer)

```
CJR.1D = "model {
  for(i in 1:n.legs)
  {
    for(j in 1:n.item)
    {
      rc[i,j] ~ dbern(p[i,j]);
      #IRT MODEL
      probit(p[i,j]) <- mu[i,j];
      mu[i,j] <- beta[j]*theta[i] - alpha[j];
    }
  }
  # SAVE ONLY A HANDFUL OF PARAMETERS
  for (y in 1:50)
  {
    Beta[y] <- beta[Y[y]];
    Alpha[y] <- alpha[Y[y]];
  }
}
```




# Modelo unidimensional del Congreso mexicano

...continuación

```
# PRIORS ON DISCRIMINATION PARAMETERS
for(j in 1:(anchor[1]-1))
{
  beta[j] ~ dnorm( 0, 0.25);
}
  beta[anchor[1]] ~ dnorm( 1, 100);
for(j in (anchor[1]+1):(anchor[2]-1))
{
  beta[j] ~ dnorm( 0, 0.25);
}
  beta[anchor[2]] ~ dnorm(-1, 100);
for(j in (anchor[2]+1):n.item)
{
  beta[j] ~ dnorm( 0, 0.25);
}
# PRIORS ON DIFFICULTY PARAMETERS
for(j in 1:n.item)
{ alpha[j] ~ dnorm( 0, 0.25); }
# PRIORS ON LEGISLATOR IDEAL POINTS
for(i in 1:n.legs)
{ theta[i] ~ dnorm(0, 1); }
```

}"

# Modelo unidimensional del Congreso mexicano (MCMCpack)




1. Test de Geweke: Compara los promedios de  $\psi$  correspondientes a dos etapas de la simulación MCMC
2. Test de Heidelberger-Welch
3. Test de Raftery-Lewis
4. Cadenas múltiples (Gelman-Rubin):

$$\widehat{\text{var}}^+(\psi|y) = \frac{T-1}{T}W + \frac{1}{T}B$$


$$\sqrt{\widehat{R}} = \sqrt{\frac{\widehat{\text{var}}^+(\psi|y)}{W}}$$

En JAGS: `gelman.diag (post.2D.cjr$mcmc)`


**Trace of theta.347.1**




**Density of theta.347.1**




**Trace of theta.348.1**




**Density of theta.348.1**




**Trace of theta.354.1**




**Density of theta.354.1**



**Trace of theta.360.1**



**Density of theta.360.1**





## Introducción

- Variables latentes

- Inferencia bayesiana

- R, RStudio y Jags (Barrios)

## Regresión lineal: El efecto de arrastre de ejecutivos

- Estimación clásica

- Estimación bayesiana

## IRT I: Introducción, teoría espacial del voto, CDHCU

## IRT II: Modelos jerárquicos, dinámicos, multidimensionales

## Modelos con variables latentes: análisis factorial bayesiano

# Modelo bidimensional del Congreso mexicano

JAGS (Plummer)



```
CJR.1D = "model {
  for(i in 1:n.legs)
  {
    for(j in 1:n.item)
    {
      rc[i,j] ~ dbern(p[i,j]);
      #IRT MODEL
      probit(p[i,j]) <- mu[i,j];
      mu[i,j] <- beta[j]*theta[i,1] +      # <= Cambio
                  delta[j]*theta[i,2] -
                  alpha[j];
    }
  }
  # PRIORS ON DIFFICULTY PARAMETERS
  for(j in 1:n.item)
  { alpha[j] ~ dnorm( 0, 0.25); }
  # PRIORS ON LEGISLATOR IDEAL POINTS
  for(i in 1:n.legs) {
    theta[i,1] ~ dnorm(0, 1);      # <= Cambio
    theta[i,2] ~ dnorm(0, 1);
  }
}
```

# Modelo bidimensional del Congreso mexicano

...continuación

```
# PRIORS ON DISCRIMINATION PARAMETERS
for(j in 1:(anchor[1]-1))
{
  beta[j] ~ dnorm( 0, 0.25);
}
  beta[anchor[1]] ~ dnorm( 1, 100);
for(j in (anchor[1]+1):(anchor[2]-1))
{
  beta[j] ~ dnorm( 0, 0.25);
}
  beta[anchor[2]] ~ dnorm(-1, 100);
for(j in (anchor[2]+1):n.item)
{
  beta[j] ~ dnorm( 0, 0.25);
}
for(j in 1:(n.item-1))          # <= Cambio
{
  delta[j] ~ dnorm( 0, 0.25);
}
  delta[n.item] ~ dnorm( 1, 4);
}"
```

# Modelo bidimensional del Congreso mexicano (MCMCpack)



## Introducción

- Variables latentes

- Inferencia bayesiana

- R, RStudio y Jags (Barrios)

## Regresión lineal: El efecto de arrastre de ejecutivos

- Estimación clásica

- Estimación bayesiana

## IRT I: Introducción, teoría espacial del voto, CDHCU

## IRT II: Modelos jerárquicos, dinámicos, multidimensionales

## Modelos con variables latentes: análisis factorial bayesiano